Ecoole Supérieur de Technologie de Khénifra
Département : Génie de l'informatique et mathématiques
Filière : ingénierie de données et intelligence artificielle
Module : Apprentissage automatique

TP 1 : Régression linéaire

On pourra se servir du cours la programmation en langage python pour les manipulations sous python de l'année dernière au besoin, on peut également consulter les pages suivantes qui contient quelques rappels utiles

- https://matplotlib.org/stable/plot_types/basic/index.html
- https://scikit-learn.org/stable/

Exercice 1 :

Pour ce TP nous allons apprendre à écrire notre premier modèle : une régression linéaire. Nous allons l'expérimenter sur un problème jouet afin de suivre pas à pas la construction et l'évaluation de notre modèle.

Dans le cas d'une régression linéaire on suppose qu'il existe une relation linéaire entre les données d'entrées et les valeurs à prédire.

Il s'agit de prédire la relation entre le prix d'une pizza et sa taille. Comme spécifié précédemment, et comme nous avons choisi une régression linéaire, cela signifie que nous faisons l'hypothèse qu'il existe une relation linaire entre le prix d'une pizza et sa taille.

Q 1 : Création et analyse des données

Nous allons tout d'abord générer un ensemble de points pour l'ensemble d'apprentissage :

Exemple	Taille	Prix
1	6	7
2	8	9
3	10	13
4	14	17,5
5	18	18

Nous allons pour cela utiliser la bibliothèque numpy:

```
import numpy as np
```

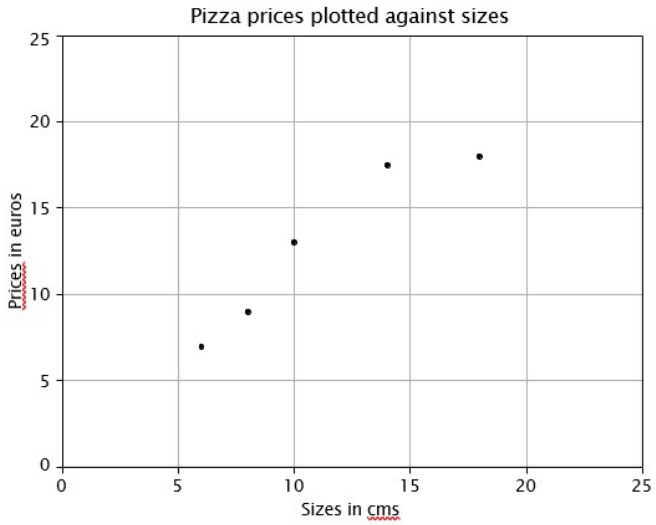
Il nous faut ensuite déclarer un tableau numpy contenant les données (tailles des pizzas) et déclarer un tableau contenant les prix correspondants.

```
X = np.array([[6], [8], [10], [14], [18]])
y = [7, 9, 13, 17.5, 18]
```

Nous souhaitons maintenant afficher les données dans un graphe afin d'examiner s'il existe une relation entre la taille et le prix d'une pizza. Pour cela nous allons utiliser matplotlib:

```
import matplotlib.pyplot as plt
```

Il faut maintenant définir le code matplotlib afin d'obtenir ce résultat :



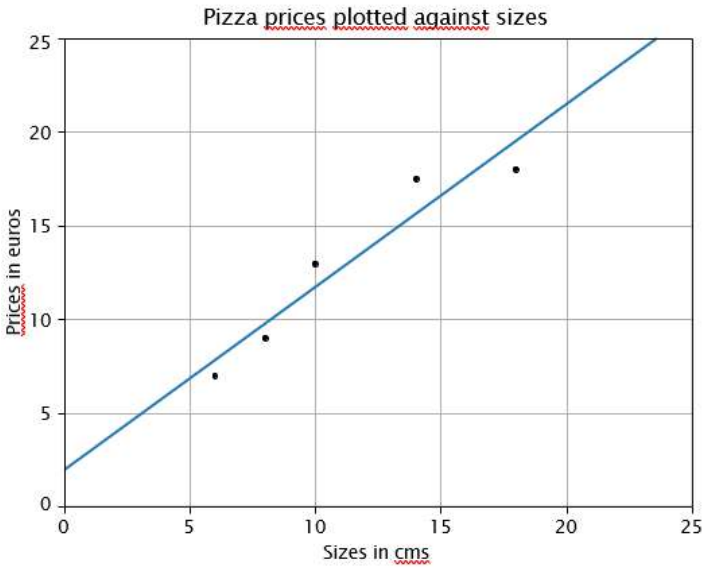
Nous pouvons constater qu'il existe bien une relation, le prix d'une pizza augmente avec sa taille, ce qui est cohérent avec notre expertise sur le sujet.

Q 2: Regression linéaire

Nous allons utiliser la bibliothèque sklearn et en particulier le modèle de régression linéaire :

```
from sklearn.linear_model import LinearRegression
```

Utiliser maintenant les fonctions fit pour l'apprentissage et predict pour prédire la réponse du modèle sur un exemple. On obtient pour notre régression linéaire :



La régression linéaire permet d'apprendre un modèle de la forme :

$$y = \alpha x + \beta$$

Q 3: Evaluation du modèle

Il nous faut maintenant évaluer notre modèle. Pour cela nous avons besoin de définir une fonction d'évaluation

Exercice 2 :

On souhaite prédire le prix d'une maison en fonction de deux variables explicatives :

- Surface (en m²)
- Nombre de chambres

- Données

Maison	Surface (m²)	Chambres	Prix (* 1000 DH)
1	50	2	150
2	65	3	200
3	80	3	220
4	120	4	330
5	100	3	280
6	90	2	250
7	150	5	400
8	70	2	210

Q1. Représenter graphiquement la relation entre chaque variable explicative (`Surface`, `Chambres`) et la variable cible (`Prix`).

Qu'est-ce que vous observez ?

Q2. Écrire le modèle de régression linéaire multiple adapté.

$$Prix = \beta_0 + \beta_1 \times Surface + \beta_2 \times Chambres + \epsilon$$

Q3. Estimer les coefficients du modèle avec Python (scikit-learn).

import pandas as pd

import matplotlib.pyplot as plt

from sklearn.linear_model import LinearRegression

Q4. Prédire le prix d'une maison de 110 m² avec 4 chambres.

```
prediction = model.predict([[110, 4]])
print("Prix prédit :", prediction)
```

Q5. Évaluer la qualité du modèle (R²).

Q6. Visualiser la relation entre les valeurs réelles et les valeurs prédites.

```
plt.scatter(y, y_pred)
plt.plot([min(y), max(y)], [min(y), max(y)], color="red")
plt.xlabel("Prix réel")
```

```
plt.ylabel("Prix prédit")
plt.title("Comparaison : Prix réels vs prédits")
plt.show()
```

Expliquer la figure?

Exercice 3 :

On considère le fichier 'Student Pass Fail Data.csv' qui contient les résultats de 1000 étudiants. Le fichier contient deux variables d'entrée : x1=Self Study Daily et x2=Tuition Monthly. La variable x1=Self Study Daily indique combien d'heures par jours l'étudiant travaille chez lui, et x2=Tuition Monthly indique combien d'heures par mois où l'étudiant suit des cours particuliers. La troisième colonne de ce fichier contient le résultat admis ou non admis. Elle représente la variable de sortie y=Fail Or Pass, et elle prend les valeurs 0 pour non admis et 1 pour admis. J'aimerais des questions sur la régression logistique pour ce sujet.

Exploration des données

1. Charger et afficher les 5 premières lignes du fichier.

   → Que représentent les variables x1, x2 et y ?

2. Calculer les statistiques descriptives de x1 (Self Study Daily) et x2 (Tuition Monthly).

   → Quels types d'étudiants semblent avoir plus de chances de réussir ?

3. Tracer un nuage de points (x1 vs x2), en colorant selon y.

   → Observe-t-on une séparation claire entre les admis (1) et les non admis (0) ?

Construction du modèle

4. Écrire le modèle de régression logistique reliant y aux variables explicatives x1 et x2.

$$P(y = 1|x_1, x_2) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2)}}$$

5. Estimer les coefficients β0, β1, β2 avec une librairie de machine learning (scikit-learn ou statsmodels).
   → Quelle est la **signe** des coefficients ? Est-il cohérent avec l'intuition ?

Évaluation du modèle

6. Calculer les probabilités prédites pour chaque étudiant.

   → Comment interpréter une probabilité de 0.85 ?

7. Choisir un seuil (par défaut 0.5) pour classer les étudiants (Pass / Fail).

   → Que se passe-t-il si on choisit un seuil de 0.3 ou 0.7 ?

8. Calculer le temps de réponse ?

Visualisation

10. Tracer la frontière de décision dans le plan (x1, x2).

    → La frontière sépare-t-elle bien les deux classes ?

Analyse approfondie

→ Comment l'augmentation d'1 heure d'étude par jour à la maison (x1) influence-t-elle la probabilité de réussite ?

→ Que se passerait-il si les deux variables étaient fortement corrélées ?